Inteligência Artificial na Nuvem

Como os principais provedores de computação em nuvem estão se adaptando à IA generativa e aos agentes

---

1. Introdução

Desde que a API da OpenAI foi liberada ao público, em novembro de 2022, a IA generativa saiu do laboratório e entrou no orçamento das empresas. Os grandes provedores de nuvem reagiram de forma parecida: revenderam modelos de terceiros como serviço gerenciado, passaram a cobrar por token e incluíram governança no pacote. O que os diferencia é o que cada um já tinha antes da IA chegar: o data warehouse da Google, o pacote de produtividade da Microsoft, o banco de dados da Oracle, a tradição em setores regulados da IBM. É aí que as propostas divergem. Este trabalho descreve o que AWS, Microsoft Azure, Google Cloud, Oracle Cloud e IBM Cloud oferecem hoje, com exemplos de uso, e compara as soluções.

2. Amazon Web Services (AWS)

A estratégia da AWS é oferecer escolha de modelo sem escolha de fornecedor. O Amazon Bedrock dá acesso por uma única API a modelos da Anthropic, Meta, Mistral, Cohere, DeepSeek e da própria Amazon (Nova e Titan), com cobrança por token e sem infraestrutura a gerenciar. Em cima vêm as Knowledge Bases para RAG, os Agents para encadear ferramentas e o Bedrock Guardrails, que a AWS afirma bloquear até 88% de conteúdo prejudicial. O SageMaker AI cobre o lado de treino e MLOps, com AutoML e os chips Trainium e Inferentia. A divisão é deliberada: Bedrock para acesso rápido e serverless, SageMaker para controle de pesos, treino e GPUs.

Aplicações práticas:

- Chatbots: agente com RAG sobre manuais, contratos e base de tickets, publicado em site, app ou Teams.
- Geração de conteúdo: o Amazon Q Developer redige textos e gera consultas SQL sobre o data lake por linguagem natural.
- Análise de dados: o Q conversa com os repositórios corporativos, resume dados e aponta tendências.
- Automação de processos: o Bedrock Flows encadeia prompts, bases de conhecimento e serviços AWS em fluxos determinísticos.

Ponto forte: a maior maturidade em conformidade (FedRAMP High, ISO, HIPAA, GDPR) e a garantia de não usar os dados do cliente para treinar modelos.

3. Microsoft Azure

O Azure veio pelo caminho inverso, do pacote de produtividade para a infraestrutura. O Microsoft Foundry (antes Azure AI Studio) unifica catálogo de modelos, execução de agentes e ferramentas prontas, como Visão, Voz, Linguagem, Tradutor, Content Safety e Document Intelligence. O diferencial é o Copilot Studio, onde o agente é descrito em linguagem natural, sem código, e publicado no Microsoft 365 Copilot, Teams,

SharePoint ou sites externos, com passagem para atendente humano. O Foundry Control Plane centraliza identidade (Entra), classificação de dados (Purview) e segurança (Defender) sobre todos os agentes.

Aplicações práticas:

- Chatbots: agentes ligados a Dynamics 365, ServiceNow, Salesforce e Genesys. A Microsoft documenta um agente de e-mail que lê solicitações de TI, extrai o número do chamado, consulta o ServiceNow e responde sozinho.
- Geração de conteúdo: Assistants de RH e vendas redigindo peças, além do Microsoft 365 Copilot operando sobre e-mail, agenda e arquivos do próprio usuário.
- Análise de dados: o agente Analyst limpa e resume números de planilhas, acionado por fluxo quando o fechamento mensal chega ao SharePoint.
- Automação de processos: Power Automate chama agentes como nó de decisão, por exemplo validando um relatório de despesas contra a política antes do lançamento contábil.

Ponto forte: a integração com o Microsoft 365 e o Power Platform, padrão em boa parte das empresas de médio porte.

4. Google Cloud

Em abril de 2026 o Google renomeou o Vertex AI para Gemini Enterprise Agent Platform, que passa a ser o caminho de evolução do produto. A plataforma dá acesso a mais de 200 modelos, entre eles Gemini 3.1 Pro e Flash, Claude, Veo para vídeo e Lyria para música, com o Agent Studio para prompts em linguagem natural e o Agent Development Kit para controle por código. Na governança, o trio Agent Identity, Agent Registry e Agent Gateway centraliza a frota de agentes e aplica confiança zero, com proteção contra prompt injection.

Aplicações práticas:

- Chatbots: arquitetura RAG de referência com Gemini e Cloud Storage, em que a pergunta recupera documentos da base e devolve a solução passo a passo. A Bell Canada reporta US$ 20 milhões de economia com agentes de autoatendimento.
- Geração de conteúdo: imagens geradas nativamente em fluxo conversacional, além de vídeo e áudio.
- Análise de dados: o BigQuery com BigQuery ML responde sobre os dados sem que eles saiam do warehouse. A Hiscox cortou de três dias para minutos a cotação de riscos complexos, e a SURA melhorou a análise de sentimento em mais de 90% das chamadas.
- Automação de processos: o BigQuery ML.predict gera previsões dentro do próprio SQL, e o agente executa a ação seguinte por chamada de função.

Ponto forte: modelo multimodal próprio combinado com o data warehouse já consolidado do Google.

5. Oracle Cloud Infrastructure (OCI)

A Oracle disputa um terreno próprio: o banco de dados e os aplicativos corporativos. O OCI Generative AI oferece LLMs para chat, geração de texto, resumo, rerank e embeddings, com API compatível com OpenAI e duas modalidades: sob demanda ou em clusters de GPU dedicados, com desempenho previsível para hospedar e ajustar modelos. A empresa mantém ainda o pacote clássico (OCI Language, Speech, Vision, Document Understanding e AI Agent Platform) e a IA dentro do próprio banco, com HeatWave GenAI rodando LLMs e busca vetorial in-database e o Select AI traduzindo perguntas em linguagem natural para SQL.

Aplicações práticas:

- Chatbots: agente com RAG consultando múltiplas fontes corporativas.
- Geração de conteúdo: resumo de conteúdo web e geração de texto com os modelos da plataforma.
- Análise de dados: o Select AI permite perguntar como estão as vendas do trimestre e receber a resposta em SQL, sobre dados que nunca saem do banco.
- Automação de processos: processamento de faturas via Document Understanding e IA já embutida nos aplicativos Fusion SaaS, sem mudança na interface.

Ponto forte: soberania de IA e custo de transição baixo para quem já usa Oracle Database e Fusion.

6. IBM Cloud (watsonx)

A IBM construiu o watsonx para um problema específico: IA em ambientes regulados, com dados que não podem sair das instalações da empresa. São quatro peças. O watsonx.ai reúne APIs, modelos da família Granite e o Prompt Lab. O watsonx.data é o lakehouse que ancora os dados para RAG em escala. O watsonx.governance trata de risco, conformidade e explicabilidade. E o watsonx Orchestrate é o mais interessante: uma camada que descobre, coordena e governa agentes de qualquer fornecedor, inclusive os que rodam no Amazon Bedrock. O Orchestrate conecta mais de 80 aplicativos, aceita raciocínio ReAct, Plan-Act ou fluxo determinístico e roteia cada etapa entre Granite, OpenAI, Anthropic, Gemini, Mistral ou Llama.

Aplicações práticas:

- Chatbots: agentes de atendimento com resposta ancorada nos dados da empresa, funcionando por web, telefone, SMS e WhatsApp.
- Geração de conteúdo: agentes de vendas que prospectam contas, preenchem o CRM e redigem e-mails personalizados.
- Análise de dados: o watsonx BI responde perguntas sobre os dados com rastreabilidade, e o watsonx.data usa agentes para acelerar a preparação de dados.
- Automação de processos: agentes prontos de RH, vendas e suprimentos, este último integrado a SAP Ariba e Coupa.

Ponto forte: agentes com governança e implantação híbrida, na nuvem pública ou no ambiente legado.

7. Comparação entre as soluções

As cinco plataformas convergem no essencial: catálogo de modelos, agentes, RAG e guardrails. O que as separa é o ponto de partida.

Provedor	Plataforma de IA	O que já existia por trás	Ponto forte	Cenário que favorece
AWS	Bedrock, SageMaker AI, Amazon Q	A maior base de infraestrutura e conformidade	Escolha de modelo sem trava de fornecedor	Empresas grandes com exigência regulatória
Microsoft	Foundry, Foundry Tools, Copilot Studio	Pacote de produtividade e Power Platform	Agente descrito em linguagem natural, sem código	Organizações já no Microsoft 365
Google Cloud	Gemini Enterprise Agent Platform	BigQuery e modelo multimodal próprio	IA e dados analíticos no mesmo lugar	Times de dados, retail, análise preditiva

Provedor	Plataforma de IA	O que já existia por trás	Ponto forte	Cenário que favorece
Oracle	OCI Enterprise AI, AI no Database	Banco de dados e Fusion SaaS	IA dentro do banco, sem mover dados	Oracle Database e Fusion, soberania de dados
IBM	watsonx.ai, .data, .governance, Orchestrate	Indústria regulada e nuvem híbrida	Governança e orquestração de agentes	Bancos, saúde, setores regulados

Principais diferenças

A primeira é o grau de automação: na AWS e no Google o desenvolvedor monta o agente com código, no Copilot Studio ele descreve em linguagem natural e a plataforma monta. A segunda é o acoplamento: Oracle e Microsoft embutem IA no produto que o cliente já usa, o banco e a planilha, o que reduz a fricção de implantação. A terceira é o posicionamento: Oracle e IBM vendem governança e residência de dados, AWS e Google vendem amplitude de modelos e desempenho.

Benefícios e limitações

O benefício comum é encurtar o caminho do piloto à produção, com API gerenciada, governança e logs prontos. O custo comum é a cobrança por token, que torna o gasto variável, e a dependência da qualidade dos dados internos: RAG não substitui governança de dados. Entre as limitações, a Microsoft perde força fora do ecossistema Microsoft 365 e em ciência de dados pura, Bedrock e Gemini cobrem bem a camada de desenvolvimento, e o watsonx tem o menor ecossistema de desenvolvedores entre os cinco.

Aplicações no mercado

As três áreas mais maduras hoje são atendimento ao cliente, análise de dados e automação de rotinas administrativas. Menos madura é a de agentes autônomos para decisão operacional, que ainda esbarra em auditoria e responsabilidade legal.

8. Conclusão

A IA deixou de ser produto separado e virou camada horizontal nas cinco plataformas. O que se observa é convergência, não guerra: mesma arquitetura (modelo, RAG, ferramentas e guardrails), mesmas promessas de segurança, mesmos casos de uso na frente. A disputa real está na borda, onde cada provedor já tem clientes, dados e regulação a seu favor.

Na prática, a escolha é ditada pelo que já existe na empresa. Time sobre Microsoft 365 tende a chegar mais longe no Copilot Studio; empresa com Oracle Database encontra a IA pronta no próprio banco; organização com governança rígida avalia IBM ou as opções de residência da Oracle; quem precisa do melhor modelo do momento vai de Bedrock ou Gemini. O erro comum é escolher o provedor pelo modelo da moda e não pelo dado que o agente precisa consultar, porque é o acesso a esse dado que decide se o projeto vira produto.

9. Referências consultadas

Fontes oficiais dos provedores, consultadas em 13/10/2026.

[1] Amazon Bedrock. AWS. https://aws.amazon.com/bedrock/. Consultado em 13/10/2026.

[2] Choosing an AWS generative AI service. AWS Docs. https://docs.aws.amazon.com/generative-ai-on-aws-how-to-choose/. Consultado em 13/10/2026.

[3] Amazon SageMaker AI. AWS. https://aws.amazon.com/sagemaker/. Consultado em 13/10/2026.

[4] Microsoft Foundry. Azure. https://azure.microsoft.com/en-us/products/ai-foundry. Consultado em 13/10/2026.

[5] What is Microsoft Foundry?. Microsoft Learn. https://learn.microsoft.com/en-us/azure/foundry/what-is-foundry. Consultado em 13/10/2026.

[6] Microsoft Copilot Studio. https://www.microsoft.com/en-us/copilot/products/copilot-studio. Consultado em 13/10/2026.

[7] Apply the structured design framework to an autonomous email support agent. Microsoft Learn. https://learn.microsoft.com/en-us/microsoft-copilot-studio/guidance/agent-design-canvas-example. Consultado em 13/10/2026.

[8] Introducing Gemini Enterprise Agent Platform. Google Cloud Blog. https://cloud.google.com/blog/products/ai-machine-learning/introducing-gemini-enterprise-agent-platform. Consultado em 13/10/2026.

[9] Gemini Enterprise AI Platform. Google Cloud. https://cloud.google.com/ai. Consultado em 13/10/2026.

[10] Generative AI use case: solutions for customer-support questions. Google Cloud Docs. https://docs.cloud.google.com/architecture/genai-customer-support. Consultado em 13/10/2026.

[11] Customers are putting Gemini to work. Google Blog. https://blog.google/innovation-and-ai/infrastructure-and-cloud/google-cloud/gemini-at-work-ai-agents/. Consultado em 13/10/2026.

[12] OCI Generative AI Overview. Oracle Docs. https://docs.oracle.com/en-us/iaas/Content/generative-ai/overview.htm. Consultado em 13/10/2026.

[13] Oracle AI Services. https://www.oracle.com/artificial-intelligence/ai-services/. Consultado em 13/10/2026.

[14] On-Demand and Dedicated Modes for OCI Generative AI Models. Oracle Docs. https://docs.oracle.com/en-us/iaas/Content/generative-ai/modes.htm. Consultado em 13/10/2026.

[15] IBM watsonx. https://www.ibm.com/products/watsonx. Consultado em 13/10/2026.

[16] IBM watsonx Orchestrate. https://www.ibm.com/products/watsonx-orchestrate. Consultado em 13/10/2026.

[17] Overview of the watsonx experience. IBM Docs. https://www.ibm.com/docs/en/watsonx/saas?topic=overview-watsonx. Consultado em 13/10/2026.